

Орлогын Таамаглалын Статистик Шинжилгээ / Income Prediction

Javkhlan

2025-12-02

Table of contents

1 Оршил (Introduction)	1
2 Өгөгдөл (Data)	2
3 Логистик загвар / Logistic Model	2
4 Кирилл үсгийн тест / Cyrillic Smoke Test	3
5 Үзүүлэлт / Metrics	3
6 Дүгнэлт / Conclusion	3
7 Ном зүй / References	3

1 Оршил (Introduction)

Энэ төслийн зорилго нь Adult Income өгөгдлийн санг ашиглан хувь хүн жилийн орлого $>50K$ эсэхийг таамаглах юм. Бид өөрсдийн хэрэгжүүлсэн логистик регресс загварыг sklearn Pipeline-той хослуулан ашигласан. Загвар нь L2 регуляризацитай, batch градиент бууруулалтаар суралцаж, сурах хурдны бууралт хэрэглэдэг.

Логистик магадлалын загвар:

$$P(Y = 1 \mid X = x) = \sigma(w^\top x + b) = \frac{1}{1 + e^{-(w^\top x + b)}} \quad (1)$$

Сургалтын алдагдал (хоёртын cross-entropy + L2):

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] + \frac{\lambda}{2m} \|w\|^2$$

Сурах хурдны бууралт:

$$\alpha_t = \frac{\alpha_0}{1 + \text{decay} \cdot t}$$

Pipeline: - Тоон шинжүүд → StandardScaler - Категори шинжүүд → OneHotEncoder(handle_unknown='ignore')
- Классын жин → class_weight='balanced'

2 Өгөгдөл (Data)

Эх сурвалж: Adult Income (Census Bureau). Зорилтот хувьсагч: income_>50K (0/1). Өгөгдөл нь тоон ба категори шинжүүдийн холимог бөгөөд ангиудын тэнцвэргүй байдал ажиглагдана (>50K нь цөөн).

- 1) Ашигласан ба унагаасан хувьсагчид (сплит хийх шатанд цөөлсөн)
 - Ашигласан (kept)
 - Тоон: age, educational-num, capital-gain, capital-loss, hours-per-week
 - Категори: education, marital-status, occupation, gender
 - Унагаасан (dropped) --- давхардал/тайлбарлах ач холбогдол бага, эсвэл дуу чимээ ихтэй баганууд:
 - Жишээлбэл: workclass, fnlwgt, relationship, race, native-country, бусад үл ашигласан бүх баганууд
- 2) Хуваалт
 - 80% сургалт, 20% баталгаажуулалт (stratify=income_>50K)
 - Хуваасны дараа зөвхөн дээрх kept баганууд болон зорилтот багана бүхий train_split.csv, val_split.csv файлд хадгалсан
- 3) Урьдчилсан боловсруулалт
 - Тоон шинжүүдийг стандартчилж, категори шинжүүдийг one-hot кодчилно
 - Үүссэн онцлог вектор дээр логистик регресс сургав:
 - learning_rate \times 0.1, max_iter \times 800, reg_lambda = 1e-4, lr_decay = 1e-4
 - class_weight = 'balanced', threshold = 0.5
- 4) Ангиудын тэнцвэргүй байдал
 - \times 50K анги нь давамгай (ихэнх), >50K анги нь цөөн тул F1/Recall зэрэг тэнцвэртэй үзүүлэлтүүдийг давхар харна. Cross-entropy алдагдал болон жинлэлт нь цөөн ангийг үл тоомсорлохоос сэргийлдэг.

3 Логистик загвар / Logistic Model

$$P(Y = 1 \mid X = x) = \text{sigma}(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (2)$$

Дээрх Equation 2 тэгшитгэл нь магадлалыг сигмоид функцээр дүрслэнэ.

4 Кирилл үсгийн тест / Cyrillic Smoke Test

Доорх мөрүүд зөв гарч буй эсэхийг PDF дээр шалгана:

Монгол хэлний кирилл: Үүнд ө, ү, ч, ж, й, h, ё тэмдэгтүүд орно.

Туршилт өгөгдөл: ``Сургалтын загвар амжилттай ажиллалаа."

English fallback: Model trained successfully.

5 Үзүүлэлт / Metrics

Metric	Value
Accuracy	0.85
Precision	0.79
Recall	0.72
F1 Score	0.75

6 Дүгнэлт / Conclusion

Энэхүү тайлан нь Adult Income өгөгдлийн сан дээр логистик регресс ашиглан орлого $>50K$ эсэхийг таамаглахад чиглэсэн. Логистик регресс нь хоёр ангиллын хоорондох магадлалыг загварчлахад ашиглагддаг статистикийн үндсэн арга юм. Манай загвар нь 85% үнэн зөв, 79% нарийвчлал, 72% сануулга, 75% F1 оноо үзүүлсэн. Эдгээр үзүүлэлтүүд нь ангиллын тэнцвэргүй байдлыг харгалзан үзэхэд чухал ач холбогдолтой.

7 Ном зүй / References